

Metodología para el uso de SPC en la base AFPDB mediante CUSUM y EWMA como estrategia de *feature engineering*

Entregable metodológico para fase preliminar del proyecto doctoral SPC-IA aplicado a ECG

Autor: Michel Alexander Castañeda Alarcón

Proyecto doctoral: Modelado de Electrocardiogramas Pediátricos basado en Gráficos de Control para la Detección Temprana de Anomalías con Inteligencia Artificial

Línea de investigación: Sistemas de Adquisición y Procesamiento de Señales

Nota metodológica: la base AFPDB corresponde a registros adultos asociados a fibrilación auricular paroxística. Por tanto, su uso se plantea como banco de prueba preliminar y traslacional para validar el módulo SPC antes de replicarlo en ECG pediátrico.

1. Enfoque metodológico

La presente fase metodológica se plantea como un estudio cuantitativo, retrospectivo, experimental y aplicado, orientado a evaluar el valor del Control Estadístico de Procesos (*Statistical Process Control*, SPC) como estrategia de extracción de características interpretables a partir de señales electrocardiográficas. Esta etapa se desarrollará sobre la base de datos pública *PAF Prediction Challenge Database* de PhysioNet, también conocida como AFPDB, con el propósito de construir y validar preliminarmente un módulo de ingeniería de características basado en gráficos CUSUM y EWMA para la predicción de fibrilación auricular paroxística.

Esta fase no sustituye la validación pediátrica posterior, sino que funciona como etapa de prueba metodológica con una base pública documentada antes de trasladar el enfoque hacia ECG pediátrico, objetivo central del proyecto doctoral. La decisión metodológica se fundamenta en que el protocolo propone integrar SPC e inteligencia artificial para generar características estadísticas trazables a partir del ECG, de modo que el módulo SPC actúe como filtro, descriptor dinámico y extractor de variables explicables antes del entrenamiento de modelos supervisados.

En términos conceptuales, el SPC permite modelar una señal fisiológica como un proceso dinámico sujeto a variabilidad común y a variabilidad especial. Desde esta perspectiva, CUSUM y EWMA no se emplean únicamente para generar alarmas, sino como transformadores estadísticos de la señal capaces de describir acumulación, persistencia, dirección y momento de aparición de desviaciones. Esta lógica resulta coherente con la literatura clásica de SPC, donde CUSUM y EWMA son especialmente útiles para identificar cambios pequeños o graduales que pueden pasar desapercibidos mediante gráficos de control convencionales (Montgomery, 2020; Page, 1954; Roberts, 1959).

2. Fuente de datos

Se utilizará la base *PAF Prediction Challenge Database v1.0.0*, disponible en PhysioNet. Esta base fue creada para el *Computers in Cardiology Challenge 2001*, cuyo objetivo fue desarrollar métodos automatizados para predecir fibrilación auricular paroxística a partir de ECG previo al evento (Moody et al., 2001). La base contiene registros ECG de dos canales y está organizada en un conjunto de aprendizaje con registros nombrados como p^* y n^* , además de un conjunto de prueba nombrado como t^* .

El conjunto de aprendizaje está compuesto por 50 conjuntos de registros. Cada conjunto contiene dos registros de 30 minutos y dos registros de continuación de 5 minutos. Dichos registros provienen de fragmentos de grabaciones ECG continuas de largo plazo correspondientes a un mismo sujeto. Los registros que inician con la letra p corresponden a sujetos con fibrilación auricular paroxística. En estos casos, el segundo registro de 30 minutos, identificado por número par, contiene el ECG inmediatamente previo a un episodio de fibrilación auricular paroxística, verificable mediante el registro de continuación correspondiente. En cambio, el primer registro de cada par, identificado por número impar, representa un periodo distante del episodio.

Los registros n^* proceden de sujetos sin fibrilación auricular documentada, incluyendo controles sanos, pacientes remitidos a monitoreo ambulatorio de largo plazo y pacientes de

unidades de cuidados intensivos. Cada archivo .dat contiene ECG digitalizado a 16 bits, con frecuencia de muestreo de 128 muestras por segundo por señal. Los archivos .hea contienen los metadatos de cabecera y los archivos .qrs proporcionan anotaciones automáticas de complejos QRS. Estas anotaciones son convenientes, pero no auditadas; por ello, deben verificarse antes de emplearse como referencia definitiva.

3. Unidad de análisis y definición de clases

La unidad primaria de análisis será el registro ECG de 30 minutos. Para la tarea supervisada principal se considerarán tres clases:

Clase	Registros	Interpretación metodológica
Pre-PAF	p* pares	Registro inmediatamente previo a un episodio de fibrilación auricular paroxística.
PAF-distant	p* impares	Registro alejado temporalmente del episodio, útil para distinguir susceptibilidad basal de transición inmediata.
No-PAF/control	n*	Registros de sujetos sin fibrilación auricular documentada.

Para evitar fuga de información, las particiones de entrenamiento y validación se realizarán agrupando por sujeto o por par de registros, de manera que registros relacionados de un mismo individuo no aparezcan simultáneamente en entrenamiento y validación. Esta decisión es indispensable porque AFPDB contiene registros relacionados dentro de un mismo monitoreo continuo; ignorar esta estructura podría inflar artificialmente el desempeño del modelo.

4. Preprocesamiento de la señal ECG

El preprocesamiento tendrá como propósito convertir la señal ECG cruda en una serie temporal apta para análisis estadístico secuencial. En primer lugar, los registros serán cargados mediante herramientas compatibles con el formato WFDB, dado que PhysioNet recomienda este ecosistema para el manejo de señales fisiológicas, cabeceras y anotaciones asociadas (Goldberger et al., 2000; Moody et al., 2022).

Posteriormente, se realizará la detección de complejos QRS y la extracción de intervalos RR. Dado que la base incluye anotaciones .qrs generadas automáticamente pero no auditadas, estas se emplearán únicamente tras una etapa de control de calidad. Cuando sea necesario, se contrastarán con detectores alternativos de QRS, como el algoritmo de Pan y Tompkins, ampliamente utilizado para la detección de complejos QRS en señales ECG (Pan & Tompkins, 1985).

A partir de las posiciones de los picos R se calculará la serie de intervalos RR, expresada en milisegundos, así como variables derivadas como diferencias sucesivas de RR, variabilidad local, media móvil, desviación estándar móvil y medidas de irregularidad. Se aplicarán criterios de limpieza para excluir intervalos fisiológicamente implausibles, errores de detección y segmentos con ruido excesivo. Los registros o ventanas que no alcancen un umbral mínimo de calidad serán excluidos de la etapa de modelado o marcados como no confiables para análisis de sensibilidad.

5. Normalización robusta por registro

Antes de aplicar los gráficos de control, las series RR y sus variables derivadas serán transformadas mediante normalización robusta. Para cada registro o sujeto se calculará una referencia basal usando la mediana y la desviación absoluta mediana escalada (*median absolute deviation*, MAD), de modo que cada observación pueda expresarse como desviación estandarizada robusta:

$$z_t = (x_t - \text{mediana}(x)) / [1.4826 \times \text{MAD}(x)]$$

donde x_t representa la variable fisiológica observada en el instante o ventana t . Esta estrategia reduce la influencia de valores extremos y resulta apropiada para señales ECG con ruido, ectopias o cambios transitorios. En los experimentos supervisados, todo parámetro de normalización será estimado únicamente con los datos de entrenamiento de cada partición, evitando que información del conjunto de validación influya en la construcción de variables.

6. Construcción de ventanas temporales

Las series RR normalizadas serán divididas en ventanas temporales consecutivas o solapadas. Se evaluarán ventanas de duración fija, por ejemplo 30, 60 y 120 segundos, así como ventanas basadas en número de latidos, por ejemplo 50, 100 o 200 intervalos RR. La elección final de la ventana se realizará dentro del conjunto de entrenamiento, comparando estabilidad estadística, sensibilidad a cambios progresivos y capacidad discriminativa para diferenciar registros pre-PAF de registros PAF-distant y controles.

Cada ventana será tratada como una unidad local de monitoreo, sobre la cual se calcularán estadísticas descriptivas convencionales y características derivadas de CUSUM y EWMA. Este diseño permite transformar una señal temporal compleja en una matriz de características interpretables por registro, conservando información sobre acumulación, persistencia, dirección y momento de aparición de desviaciones.

7. Aplicación de CUSUM como extractor de características

El gráfico CUSUM (*Cumulative Sum Control Chart*) será utilizado para detectar cambios pequeños, persistentes y acumulativos en la serie RR normalizada. A diferencia de un gráfico Shewhart, que responde principalmente a desviaciones abruptas, CUSUM acumula evidencia secuencial de desplazamientos sostenidos respecto al comportamiento esperado del proceso. Esta propiedad lo hace adecuado para estudiar cambios graduales previos a la fibrilación auricular paroxística, donde el interés no se limita al valor aislado del intervalo RR, sino a la trayectoria de inestabilidad que precede al evento.

El estadístico CUSUM bilateral se calculará mediante:

$$C_{t+} = \max(0, C_{(t-1)+} + z_t - k)$$

$$C_{t-} = \max(0, C_{(t-1)-} - z_t - k)$$

donde C_{t+} acumula desviaciones positivas, C_{t-} acumula desviaciones negativas, z_t es la observación normalizada y k representa el valor de referencia o magnitud mínima de cambio clínicamente relevante. Se generará una alarma cuando C_{t+} o C_{t-} exceda un umbral h . La

formulación CUSUM se basa en los principios propuestos por Page (1954) y desarrollados posteriormente dentro del marco del SPC moderno (Montgomery, 2020).

7.1 Características derivadas de CUSUM

Familia	Variable propuesta	Interpretación
Magnitud acumulada	Máximo C+, máximo C-, máximo absoluto CUSUM	Intensidad del desplazamiento acumulado.
Persistencia	Número de puntos sobre umbral; duración total en alarma	Grado de permanencia del comportamiento anómalo.
Temporalidad	Tiempo hasta primera alarma; ventana de primera alarma	Momento en que inicia la desviación.
Dirección	Dominancia C+ - C-; razón C+/C-	Tendencia hacia aumento o disminución de la variable RR.
Área acumulada	Área bajo la curva CUSUM positiva y negativa	Carga total de desviación durante el registro.
Dinámica	Pendiente CUSUM por terciles temporales	Aceleración o desaceleración del cambio.
Estabilidad	Número de reinicios a cero	Intermitencia del proceso.

En los registros pre-PAF, el tiempo hasta la primera alarma se convertirá en una variable de anticipación. Si la primera alarma ocurre antes del inicio de la fibrilación auricular observado en el registro de continuación, se calculará el tiempo de anticipación como la diferencia entre el final del registro de 30 minutos y el instante de la primera alarma sostenida. En los registros PAF-distant y controles, las alarmas se interpretarán como posibles falsas alarmas o señales de inestabilidad no asociadas al evento inmediato.

8. Aplicación de EWMA como extractor de características

El gráfico EWMA (*Exponentially Weighted Moving Average*) será utilizado para capturar desplazamientos graduales en la media local de la serie RR o de sus variables derivadas. A diferencia de CUSUM, que acumula desviaciones respecto a una referencia, EWMA produce una estimación suavizada del estado reciente del proceso, asignando mayor peso a las observaciones recientes y menor peso a las observaciones pasadas. Esta lógica resulta útil cuando el fenómeno de interés se expresa como transición progresiva, no necesariamente como ruptura abrupta.

El estadístico EWMA se calculará como:

$$E_t = \lambda z_t + (1 - \lambda) E_{(t-1)}$$

donde E_t representa el promedio móvil exponencialmente ponderado en el instante t , z_t es la observación normalizada y λ es el parámetro de suavizamiento, con $0 < \lambda \leq 1$. Valores pequeños de λ producen mayor suavizamiento y sensibilidad a cambios persistentes; valores mayores responden más rápido a cambios recientes. La formulación EWMA se vincula con los gráficos de medias móviles geométricas propuestos por Roberts (1959) y con desarrollos posteriores sobre propiedades y mejoras de esquemas EWMA (Lucas & Saccucci, 1990).

Los límites de control EWMA se definirán considerando la varianza esperada del estadístico suavizado. Para una serie estandarizada, podrán expresarse de forma general como:

$$LCL_t, UCL_t = \pm L \sqrt{\lambda/(2 - \lambda) [1 - (1 - \lambda)^{2t}]}$$

donde L representa el multiplicador de control. Los parámetros λ y L serán seleccionados exclusivamente dentro del conjunto de entrenamiento, evitando optimizar sobre los datos de validación.

8.1 Características derivadas de EWMA

Familia	Variable propuesta	Interpretación
Desplazamiento suavizado	Máximo EWMA, mínimo EWMA, máximo absoluto EWMA	Magnitud del cambio progresivo.
Control estadístico	Número de puntos fuera de límites EWMA	Frecuencia de comportamiento fuera de control.
Persistencia	Duración total fuera de control	Continuidad temporal de la desviación.
Temporalidad	Tiempo hasta primera salida EWMA	Aparición temprana de inestabilidad.
Tendencia	Pendiente EWMA global y por segmentos	Dirección y velocidad del cambio.
Carga anómala	Área absoluta bajo EWMA	Intensidad total del desplazamiento.
Estado final	Valor EWMA en el último tercio del registro	Condición cercana al evento o al cierre del segmento.

Estas variables no se interpretarán como diagnóstico clínico directo, sino como descriptores estadísticos de la dinámica previa al evento. Su aporte principal será convertir la señal ECG en un conjunto de indicadores con significado temporal, acumulativo y explicable.

9. Integración de CUSUM y EWMA como feature engineering

El módulo SPC producirá una matriz final de características por registro. Esta matriz integrará variables convencionales de variabilidad RR, características CUSUM y características EWMA. La lógica de integración se organizará en tres niveles: características fisiológicas base, características CUSUM y características EWMA.

Nivel	Variables incluidas	Propósito
Fisiológico base	Media RR, desviación estándar RR, RMSSD, proporción de cambios abruptos, variabilidad por ventana	Establecer una línea base fisiológica convencional.
CUSUM	Acumulación, persistencia, dirección y tiempo de aparición de desviaciones	Capturar evidencia acumulativa de cambio sostenido.
EWMA	Tendencia suavizada, desplazamiento progresivo, duración fuera de control y estado final	Caracterizar transiciones graduales del proceso.

Desde el punto de vista metodológico, CUSUM y EWMA no se usarán únicamente para detectar alarmas, sino como transformadores estadísticos de la señal. La contribución del SPC será convertir una serie RR irregular en variables que describen cómo cambia el proceso, cuándo cambia, cuánto se acumula la desviación y qué tan persistente es la transición.

10. Modelado supervisado

Una vez construida la matriz de características, se entrenarán modelos supervisados para clasificar registros pre-PAF frente a registros PAF-distant y controles. Inicialmente se emplearán modelos interpretables o seminterpretables, como regresión logística regularizada, Random Forest y Gradient Boosting. Posteriormente, se podrán comparar con modelos secuenciales o híbridos que incorporen directamente las trayectorias CUSUM/EWMA como series temporales de entrada.

Configuración	Variables incluidas	Propósito
Modelo base	Variables RR/HRV convencionales	Establecer línea base.
Modelo SPC	Variables CUSUM + EWMA	Medir aporte específico del SPC.
Modelo combinado	RR/HRV + CUSUM + EWMA	Evaluar mejora por integración.

Esta comparación permitirá determinar si las características generadas mediante SPC aportan información adicional respecto a los descriptores convencionales de variabilidad cardíaca. Sin esta comparación, el uso de CUSUM y EWMA quedaría como una transformación estadística sin evidencia empírica de valor añadido.

11. Validación y métricas de desempeño

La validación se realizará mediante particiones agrupadas por sujeto o por par de registros, utilizando estrategias como *Group k-fold cross-validation*. En cada partición, la selección de parámetros de CUSUM, EWMA, normalización, escalamiento, selección de variables y ajuste de umbrales se hará únicamente con datos de entrenamiento. Los datos de validación permanecerán completamente aislados hasta la evaluación final.

Las métricas principales serán sensibilidad, especificidad, exactitud balanceada, AUC-ROC y AUC-PR. En caso de comparar dos modelos sobre las mismas particiones, se podrá emplear la prueba de DeLong para comparar áreas bajo la curva ROC y la prueba de McNemar para contrastar diferencias en errores de clasificación pareada (DeLong et al., 1988).

11.1 Métricas temporales

Métrica temporal	Definición	Aplicación
Tiempo hasta primera alarma	Primer instante en que CUSUM o EWMA cruza umbral.	Registros pre-PAF.
Tiempo de anticipación	Diferencia entre final del registro y primera alarma sostenida.	Registros pre-PAF.
Falsas alarmas por hora	Número de alarmas en registros PAF-distant o controles.	Control de especificidad temporal.
Porcentaje de tiempo en alarma	Proporción del registro bajo estado fuera de control.	Persistencia de anomalía.
Densidad de alarmas	Alarmas por ventana válida.	Comparabilidad entre registros.

Estas métricas permitirán evaluar no solo si el modelo clasifica correctamente, sino si el sistema ofrece señales tempranas interpretables antes del evento. Esta distinción es central: clasificar un registro completo como pre-PAF no equivale automáticamente a demostrar

detección temprana.

12. Control de sesgos y reproducibilidad

Para fortalecer la validez interna del estudio se aplicarán los siguientes controles: primero, se evitará la fuga de información mediante particiones agrupadas por sujeto o par de registros; segundo, los parámetros de normalización y de los gráficos CUSUM/EWMA serán aprendidos exclusivamente en entrenamiento; tercero, los registros de continuación c se usarán para verificar la relación temporal con el evento, pero no para alimentar directamente el modelo predictivo; cuarto, las anotaciones .qrs serán verificadas debido a que son anotaciones automáticas; quinto, se documentará cada experimento mediante semillas aleatorias, versiones de librerías, configuración de ventanas, parámetros CUSUM/EWMA y métricas obtenidas.

La reproducibilidad se asegurará mediante scripts versionados en Python, utilizando bibliotecas como wfdb, numpy, pandas, scipy, scikit-learn y herramientas de visualización para generar gráficos de control, curvas ROC, matrices de confusión y reportes de importancia de variables. El uso de WFDB facilita el procesamiento estandarizado de bases PhysioNet (Moody et al., 2022).

13. Interpretación metodológica esperada

El resultado esperado de esta fase no será únicamente un clasificador de fibrilación auricular paroxística, sino una metodología replicable para transformar señales ECG en variables estadísticas interpretables. En particular, se espera que CUSUM capture acumulaciones progresivas de desviación en la dinámica RR, mientras que EWMA describa desplazamientos suavizados del proceso fisiológico. Si estas variables mejoran la discriminación entre registros pre-PAF y registros alejados del evento, se obtendrá evidencia preliminar de que el SPC puede aportar valor como capa de ingeniería de características en bioseñales.

Esta evidencia servirá como base metodológica para trasladar posteriormente el enfoque a ECG pediátrico, donde la alta variabilidad fisiológica por edad exige modelos más adaptativos, personalizados y explicables. La aportación doctoral no debe formularse como simple aplicación de CUSUM y EWMA, sino como la construcción de una capa estadística intermedia que permite caracterizar transiciones fisiológicas antes de alimentar modelos de inteligencia artificial.

Referencias

- DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837-845.
- Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C.-K., & Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23), e215-e220.
- Lucas, J. M., & Saccucci, M. S. (1990). Exponentially weighted moving average control schemes: Properties and enhancements. *Technometrics*, 32(1), 1-12.
- Montgomery, D. C. (2020). *Introduction to statistical quality control* (8th ed.). Wiley.
- Moody, G. B., Goldberger, A. L., McClennen, S., & Swiryn, S. P. (2001). Predicting the onset of paroxysmal atrial fibrillation: The Computers in Cardiology Challenge 2001. *Computers in Cardiology*, 28, 113-116.
- Moody, G., Pollard, T., & Moody, B. (2022). *WFDB Software Package* (Version 10.7.0). PhysioNet.
- Page, E. S. (1954). Continuous inspection schemes. *Biometrika*, 41(1-2), 100-115.
- Pan, J., & Tompkins, W. J. (1985). A real-time QRS detection algorithm. *IEEE Transactions on Biomedical Engineering*, 32(3), 230-236.
- Roberts, S. W. (1959). Control chart tests based on geometric moving averages. *Technometrics*, 1(3), 239-250.